


EDA Completo + Teste de Hipótese



Análise Exploratória dos Dados

(variáveis textuais)

- **Passos do EDA:**

- Compreensão do problema e do dataset
- Inspeção inicial
- Verificação da qualidade dos dados
- Limpeza e preparação dos dados
- Análise Univariada
- Análise Multivariada
- Identificação de Outliers e Anomalias
- Documentação do EDA e conclusões



Limpeza e Preparação dos Dados

(variáveis textuais)

- **Principais operações:**

1. Remover/tratar registros duplicados desnecessários;
2. Remover/tratar valores ausentes tratados de forma justificada;
3. Corrigir tipos das colunas;
4. Corrigir espaços, erros de preenchimento e inconsistências evidentes;
5. Corrigir valores inválidos.
6. Remover caracteres de pontuação
7. Contagem de número de palavras e tamanho do texto
8. Vetorização de contagem de palavras



Análise Univariada (**variáveis textuais**)

- **Variáveis numéricas:**
 1. média, mediana, mínimo e máximo;
 2. quartis, variância e desvio-padrão;
 3. distribuição dos valores;
- **Variáveis categóricas:**
 1. quantidade de categorias;
 2. frequência absoluta e relativa;
 3. categoria mais frequente;
- **Variáveis textuais:**
 1. estatísticas tamanho do texto e quantidade palavras;
 2. distribuição tamanho do texto e quantidade de palavras;
 3. palavras mais frequentes;



Análise Multivariada (variáveis textuais)

- **Variáveis numéricas:**
 1. Correlação linear entre alvo x independentes
 2. Correlação linear entre variáveis independentes
 3. Correlação não-linear entre alvo x independentes
 4. Correlação não-linear entre variáveis independentes
 5. Analisar variáveis preditoras
 6. Analisar e tratar variáveis redundantes
- **Variáveis categóricas:**
 1. Associação entre alvo x independentes
 2. Associação entre variáveis independentes
 3. Analisar variáveis preditoras
 4. Analisar e tratar variáveis redundantes
- **Variáveis textuais:**
 - Associação entre variáveis do CountVectorizer x alvo
 - Associação entre variáveis do CountVectorizer
 - Analisar variáveis preditoras do CountVectorizer
 - Analisar e tratar variáveis redundantes do CountVectorizer



Identificar outliers e anomalias

- **Variáveis numéricas:**
 1. Selecionar método de identificação de outlier;
 1. Q-Q Plot, Skewness, Teste Shapiro-Wilk
 2. Identificar outliers com IQR ou ZScore
- **Variáveis categóricas:**
 1. Identificar categorias raras;
 2. Identificar possível desequilíbrio entre as classes.
- **Variáveis textuais:**
 1. Criar/identificar variáveis numéricas a partir da variável textual
 - 1.1. Selecionar método de identificação de outlier;
 - 1.1.1. Q-Q Plot, Skewness, Teste Shapiro-Wilk
 - 1.2. Identificar outliers com IQR ou ZScore
 2. Identificar termos raros do CountVectorizer



Teste de hipótese

- **Passos para teste de hipótese:**
 - Formular as hipóteses
 - H_0 : hipótese nula
 - H_1 : hipótese alternativa
 - Definir o nível de significância (geralmente, $\alpha = 0,05$)
 - Escolher teste estatístico (Teste t ou Mann-Whitney)
 - Aplicar o teste estatístico
 - Tomar a decisão
 - Se $p < \alpha \rightarrow$ rejeita H_0
 - Se $p \geq \alpha \rightarrow$ não rejeita H_0



Teste de hipótese

- **Exemplo:**
 - H_0 : Cancelamento e Atraso possuem a mesma média de palavras.
 - H_1 : Cancelamento e Atraso possuem médias de palavras diferentes.
- **Se teste retornar:** $p = 0,01$ e $\alpha = 0,05$
Então: $p < \alpha \rightarrow$ rejeita H_0
 - **Conclusão:** Existe evidência de diferença na quantidade média de palavras entre as duas intenções.
- **Se teste retornar:** $p = 0,30$ e $\alpha = 0,05$
Então: $p \geq \alpha \rightarrow$ não rejeita H_0
 - **Conclusão:** Não há evidência suficiente para afirmar que as médias são diferentes.



Teste de hipótese

- **Teste t e teste Mann-Whitney:** testes para verificar se **dois grupos apresentam valores diferentes para uma determinada variável**
 - **Teste t:**
 - Amostras independentes
 - Compara média de dois grupos
 - **Teste Mann-Whitney:**
 - distribuição muito assimétrica
 - muitos outliers
 - ausência de normalidade
 - valores discretos ou distribuições estranhas



Teste de hipótese

- **Exemplo dataset:**

texto	intenção	qtd_palavras
"quero cancelar meu pedido"	cancelamento	4
"meu produto ainda não chegou"	atraso	5
"cancele minha compra"	cancelamento	3
"gostaria de saber onde está meu pedido"	atraso	7

- **Objetivo:**

- Comparar cancelamento x atraso em relação a quantidade de palavras

Teste de hipótese

- **Teste t:** verifica se a média de uma variável numérica é diferente entre dois grupos
 - Exemplo:
 - Cancelamento: média = 6,2 palavras
 - Atraso: média = 9,8 palavras
- **Estatística t:**
 - t grande: grande diferença entre as médias
 - t pequeno: pequena diferença entre as médias
- **p-valor:**
 - **$p < 0,05$:** diferença estatisticamente significativa
 - **$p \geq 0,05$:** não há evidência suficiente de diferença
- **Teste t de Welch:** grupos podem ter variâncias diferentes



Teste de hipótese

- **Teste Mann-Whitney:** verifica se os valores de um grupo tendem a ser maiores ou menores que os valores do outro grupo
 - **Exemplo:**
 - Cancelamento: 3, 4, 5, 5, 6
 - Atraso: 7, 8, 9, 10, 12
 - Valores (dois grupos) ordenados: 3 4 5 5 6 7 8 9 10 12
 - Valor e ranks: 3 (1), 4 (2), 5 (3,5), 5 (3,5), 6 (5), 7 (6), 8 (7), 9 (8), 10 (9), 12 (10)
- **Estatística U:** a partir desses ranks, verifica se essa separação é grande demais para ser explicada pelo acaso
 - U próximo de 0: forte separação em uma direção.
 - U maior do que 0: grupos tendem a estar misturados
- **two-sided:** verificar qualquer diferença entre os grupos

